

The Interpolation Method of Electricity Consumption Data by Business Using LSTM and GRU

LSTM과 GRU를 활용한 업종별 전력사용량 데이터 보간 방법

Min-young Jang · Jung-il Lee · Nam-joon Jung · Yeong-jun Koh

장민영[†] · 이정일^{*} · 정남준^{*} · 고영준^{**}

Abstract

The electricity consumption data is collected using the communication network from the smart meter. Missing values occur depending on the status of the meter and the communication network environment. In previous studies, missing value interpolation was suggested as a method of using electricity users' past electricity usage patterns, but autocorrelation in artificial intelligence techniques can reduce generalization performance. In this study, the method of generating deep learning models by business improved the stability and efficiency of the model compared to the method of interpolation by electricity user. An interpolation model creation method was presented by comparing four LSTM models with higher accuracy than GRU.

Key Words

Interpolation Method, Electricity Consumption Data, LSTM(Long Short-Term Memory), GRU(Gated Recurrent Unit)

1. 서론

전력사용량 데이터(Load Profile, LP)는 시간 단위로 측정된 대표적인 시계열 데이터이다. 전기사용자의 원격검침계기에서 생성되는 데이터는 유·무선 통신망을 이용하여 수집되며, 원격 검침계기 상태와 통신망 환경에 따라 결측치 비율이 달리 나타난다. 국내 연구에서는 전기사용자의 과거 전기사용 패턴을 기반으로 결측치 보간 모델을 제시하였다[1]. 하지만 데이터에 의존적인 인공지능 기법에서는 자기상관성이 오히려 일반화 성능을 떨어뜨려 문제가 될 수 있다. 선행 연구에서는 전력사용량 데이터의 유사도(Similarity)를 기반으로 동시간대 유사 전기사용자의 전력사용량 값으로 결측치를 보간하는 방법을 제시하였다.[2] 본 연구에서는 딥러닝 기술을 기반으로 같은 업종의 전력사용량 데이터를 학습에 이용하여 인공지능 일반화 성능을 향상시키면서, 전력사용량 보간 성능을 높이는 방법을 제시한다. 본 논문의 구성은 2장에서 딥러닝 아키텍처와 결측치 형태에 대한 관련 이론을 설명한다. 3장에서는 보간 모델의 입력 변수를 설계하고, 딥러닝 생성 방식을 검토한다. 그리고 LSTM과 GRU의 성능을 비교하여 최종적으로 LSTM을 이용한 보간

모델의 성능에 대한 실험 결과를 도출하고 4장에서 결론을 맺는다.

2. 관련 이론

2.1 LSTM, GRU 개요

LSTM(Long Short-Term Memory)는 RNN(Recurrent Neural Network)의 한 종류로 기존의 RNN에 있던 vanishing & exploding gradient 문제를 해결하기 위한 모델이다. RNN은 현재 시점 t 에서 이전 시점의 모든 입력을 받는 구조이므로 이를 메모리의 한 형태로 볼 수 있다. LSTM은 이런 메모리 역할을 하는 각각의 노드에 망각, 입력, 출력 게이트를 추가하여 LSTM Cell을 구성한다[3, 4].

LSTM Cell은 두 개 상태 벡터 $h(t)$ 와 $C(t)$ 로 구성한다. $h(t)$ 는 단기 상태, $C(t)$ 는 장기 상태를 나타낸다. 장기 상태 $C(t-1)$ 는 LSTM Cell을 통과하면서 망각 게이트(forget gate)를 지나면서 기억의 일부를 잃고, 입력 게이트(input gate)로부터 신규 기억을 추가한다. 이렇게 만들어진 장기 상태 $C(t)$ 를 그대로 바로 출력으로 보낸다. 그리고 $C(t)$ 를 복사하여 출력 게이트(output

[†] Corresponding Author: KEPCO Korea Electric Power Research Institute(KEPRI), Korea.
E-mail: dearjmy@kepcor.co.kr

<https://orcid.org/0000-0002-3605-3468>

^{*} KEPCO Korea Electric Power Research Institute(KEPRI), Korea.

<https://orcid.org/0000-0002-0719-312X>

<https://orcid.org/0000-0003-3334-2384>

^{**}Department of Computer Engineering, Chungnam Nat'l University, Korea.

<https://orcid.org/0000-0003-1805-2960>

Received: Nov. 09, 2022 Revised: Feb. 09, 2023 Accepted: Feb. 21, 2023

Copyright © The Korean Institute of Electrical Engineers

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/4.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

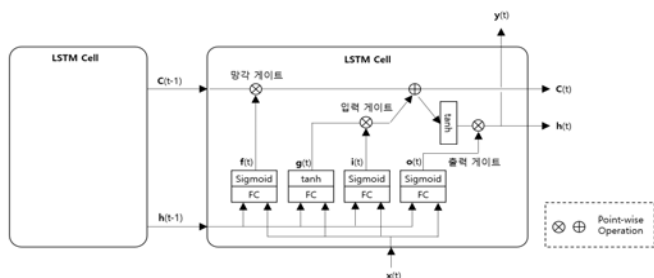


그림 1 LSTM cell 구조
Fig. 1 LSTM cell structure

gate)의 tanh 함수로 전달하고, 단기 상태 $h(t)$ 와 LSTM Cell의 출력인 $y(t)$ 를 만든다. 새로운 기억은 현재 시점 입력 벡터 $x(t)$ 와 현재 시점 바로 이전의 단기 상태 $h(t-1)$ 으로 만드는데, 여기에 필요한 값들은 4개의 다른 완전 연결 층으로 입력한다. 주 층은 $g(t)$ 를 출력하는 층인데, 이 층은 $x(t)$ 와 $h(t-1)$ 을 가지고 이번 시점에 기억해야 할 정보의 양을 정한다. 나머지 세 개의 다른 층은 게이트 제어기이다. 각 게이트 제어기의 역할은 다음과 같다. 망각 게이트(forget gate, $f(t)$)는 장기 상태의 삭제 할 부분을 제어한다. 입력 게이트(input gate, $i(t)$)는 어느 부분을 장기 상태에 추가할지 제어한다. 출력 게이트(output gate, $o(t)$)는 장기 상태의 특징 중 일부분을 현재 시점의 $h(t)$ 와 $y(t)$ 로 출력 여부를 제어한다.

GRU(Gated Recurrent Unit)은 2014년에 공개된 모델로 LSTM 구조를 간략화한 변형모델 중 하나이다. LSTM은 중요한 정보는 장기간 기억하고 흔한 정보는 단기간 기억하는 인간의 기억 처리 과정을 잘 묘사했지만, 다소 복잡한 내부 구조 때문에 학습 시간이 상대적으로 오래 걸리는 등 일부 단점을 가지고 있다. GRU는 LSTM의 구조를 간소화하기 위하여, 장기 상태와 단기 상태를 하나의 벡터로 합치고 망각 게이트(forget gate)와 입력 게이트(input gate)를 갱신 게이트(update gate)로 통합하였다.

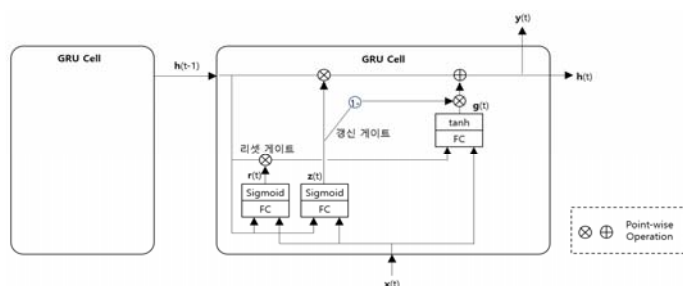


그림 2 GRU cell 구조
Fig. 2 GRU cell structure

GRU Cell의 리셋 게이트(reset gate, $r(t)$)는 이전 시점의 $h(t-1)$ 과 현재 시점의 $x(t)$ 를 사용하여, 이전의 기억을 얼마나 잊어야 하는지를 결정한다. 갱신 게이트(update gate, $z(t)$)는 이전 시점의 기억을 얼마나 유지시킬지 결정하는데, $z(t)=0$ 이면 이전 시

점의 기억 $h(t-1)$ 을 유지하고, $z(t)=1$ 이면 $g(t)$ 로 값을 대체한다. 출력 게이트(output gate)는 별도로 존재하지 않으며, 매 시점마다 전체 상태 벡터가 출력된다[5, 6].

본 연구에서는 시계열 데이터 학습에서 좋은 성능을 보이고 있는 LSTM과 GRU 모델을 선택하여 보간 모델을 설계하기로 하였다. 보간 모델은 데이터가 생성된 이후에 그 결과를 보완하는 역할이며, 이러한 점 때문에 실시간 딥러닝 처리에서 중요한 요소인 속도보다 모델의 정확도가 더 효과적일 수 있다. 그래서 LSTM과 GRU의 성능을 비교하여 최종적으로 보간에 유리한 모델을 선정한다.

2.2 전력사용량 데이터의 결측치 형태

결측 데이터 종류는 크게 3가지 형태로 나눌 수 있다. 첫 번째, 완전 무작위 결측(MCAR : Missing Completely At Random)은 결측치가 데이터 전체 분포에서 무작위로 발생한 경우이다. 입력 변수의 종류나 변수의 값과 상관없이 비슷한 분포로 누락된 경우를 의미한다. 관측치와 결측치 모두 결측의 발생 원인은 독립적이다[6]. 두 번째, 무작위 결측(MAR : Missing At Random)은 입력 변수 내 특정 변수에 대해 데이터가 누락되는 것을 말하며, 결측치가 발생하는 이유가 다른 변수와 관련이 있음을 의미한다. 관측치로부터 결측치를 추정하는 것이 가능하게 되므로, 결측치를 대체하기 위해 변수와의 상관성을 이용하는 방법 등을 사용할 수 있다[6]. 세 번째, 비무작위 결측(MNAR : Missing Not At Random)은 결측치의 발생이 무작위로 발생하는 것이 아니라 결측이 발생한 이유와 관련이 있는 경우이다. 결측치의 발생이 어떤 인과 구조에 의해 발생하는 것이 아니며, 관측값과 관련이 있다[7].

전력사용량 데이터의 결측값은 원격검침계기(스마트미터)의 상태나 통신망의 품질 문제로 발생하며, 이는 완전 무작위 결측(MCAR)과 같다. 결측 원인이 다른 변수와 관련성이 없기 때문에, 훈련 샘플에서 삭제를 해도 비교적 예측 결과에 영향이 제한적이다. 이러한 이유로 본 연구에서는 결측값이 많은 일자의 데이터는 제거하고, 결측치가 거의 없는 고품질 데이터를 활용하여 시계열 모델링을 통해 미래값을 예측하는 방법을 선택한다.

3. 보간 모델 실험

3.1 보간 모델의 입력 변수 설계

본 연구에서는 한국전력공사의 전력 데이터 공유센터에서 학술용으로 공유하는 전력사용량 데이터를 활용한다. 전력사용량 데이터는 원격검침계기로부터 15분 또는 1시간 단위로 수집한다. 수집 주기에 차이는 원격검침계기의 종류에 따라 달라지며, 이는 전기사용자의 전기사용계약에 따라 수집하는 데이터의 범위가 다르기 때문이다. 그렇기 때문에 주기가 다른 데이터를 1

시간 단위로 통일하는 데이터 전처리 작업을 수행한다.

전력사용량 데이터는 10개의 대표 업종을 선별하여 사용한다. 각 업종별로 20개씩 총 200개의 데이터셋을 구성하였으며, 데이터 수집 기간은 2021.8-9월로 2개월간의 데이터를 사용한다. 결측값이 많은 일자의 데이터는 분석 대상에서 제외하고, 데이터 주기를 1시간 단위로 조정한다.

전력사용량 데이터 보간을 2가지 방식으로 검토한다. 첫 번째는 전력사용량 데이터의 자기상관성을 이용하여 전기사용자 개별의 전력사용량 데이터를 학습 데이터로 보간하는 방법이다. 두 번째는 업종별 전력사용 패턴의 상관성을 이용하여 업종별 전력사용량 데이터를 그룹화하여 학습하는 방법이다. 2가지 방식의 타당성 검증을 위하여 전력사용량 데이터의 자기상관계수(Autocorrelation coefficient)와 업종별 상관관계수(Correlation coefficients)를 분석한다.

자기상관계수는 순차 데이터의 시차 값 사이의 선형 관계를 측정하는 것이고, 수식은 (1)와 같다.

$$r_k = \frac{\sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2} \quad (1)$$

전력사용량 데이터는 24시간의 주기를 가지므로 $k=24$ 일 때, 전기사용자별 자기상관계수를 계산한다.

업종별 상관관계수는 두 변수 사이의 선형 관계의 크기를 측정하는 것이고, 수식은 (2)와 같다.

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2)$$

업종별 상관관계수는 전기사용자별로 24시간 주기의 데이터 분포를 기준으로 측정하였으며, 각 업종별 20개씩의 데이터 샘플에 대해 상관관계수를 계산하여 평균한다.

전력사용량 데이터의 자기상관계수와 업종별 상관관계수 계산 결과는 표 1과 같다.

표 1 자기상관계수와 업종별 상관관계수 비교

Table 1 Comparison of autocorrelation coefficient and correlation coefficient by business

	MIN	MAX	Avg.
Autocorrelation coefficient	0.035	0.969	0.616
Correlation coefficient by business	0.347	0.537	0.459

전력사용량 데이터의 자기상관계수의 평균값은 0.616으로 업종별 전력사용량 데이터 상관관계수보다 약 0.157이 높게 나타났다. 하지만 최소값은 0.035로 상관성이 매우 낮은 전기사용자 데이터도 존재한다. 데이터 분포값이 유사한 데이터를 사용하면 딥러닝 모델의 일반화 성능을 높일 수 있다. 실험계획 수립시 전기사용자별 학습 데이터를 생성하는 방법과 업종별로 학습 데이터를 생성하는 방법을 검토한다.

전력사용량 데이터는 기상 데이터와 상관관계는 이전의 많은 연구에서 다루어진 내용이다. 본 연구에서는 입력변수 설계와 검증 차원에서 업종별 전력사용량과 기상 데이터간의 상관관계를 분석한다. 기상 데이터는 기상청에서 개방한 데이터를 수집하여 기온(°C), 강수량(mm), 습도(%) 데이터를 요인으로 선정한다.

The Result of Correlation Analysis between LP and Weather

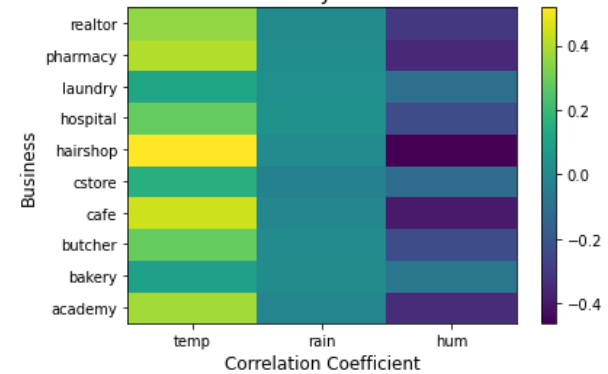


그림 3 전력사용량과 기상과의 상관관계 분석 결과

Fig. 3 Correlation analysis result between electricity consumption and weather

상관관계 분석결과를 그림 3과 같다. 전력사용량은 기온은 양(+)의 상관관계를 보이고, 습도와는 음(-)의 상관관계를 보이고 있다. 기온에 민감한 업종은 습도에서도 동일하게 높은 상관관계를 보인다. 특히 커피숍, 미용실, 약국이 상대적으로 높은 상관관계를 보인다. 세탁소, 편의점, 제과점은 다른 업종과 비교하여 약한 상관관계를 나타낸다. 업종에 따라 일부 다른 특성을 보이지만 다수 업종에서 전력사용량과 온도, 습도 데이터의 상관관계는 유의미하다고 할 수 있다.

상기 분석결과에 따라 보간 모델의 입력 변수는 분석의 효율성을 고려하여 전력사용량과 온도 데이터로 선정하였다. 입력 변수는 시간 단위의 전력사용량(x_1)과 온도 데이터(x_2)를 묶음으로 2차원 텐서(tensor)를 구성한다.

데이터 보간을 위한 이전 연구의 사례를 보면 과거 시퀀스 데이터를 이용하여 결측치를 예측하는 방식을 주로 제안하였다. 본 연구에서도 이와 같은 방식을 채택하여 과거 24시간의 데이터 시퀀스를 기반으로 결측치를 예측하는 형태로 데이터 보간 모델링을 수행한다. 24시간 데이터를 사용하는 이유는 전기사용자의 전력사용량이 하루를 주기로 반복적인 패턴을 보이기 때문이다. 최종적인 입력 변수 설계는 3차원 텐서(tensor)

로 식 (3)와 같이 정의한다.

$$\mathbf{X} = \{\{x_1(t-24), x_2(t-24)\}, \{x_1(t-23), x_2(t-23)\}, \dots, \{x_1(t-2), x_2(t-2)\}, \{x_1(t-1), x_2(t-1)\}\}$$

$$y = y(t) \quad (3)$$

3.2 딥러닝 모델 생성 방식 검토 실험

딥러닝 모델을 생성하는 방법으로 2가지 방식을 검토한다. 전기사용자별 딥러닝 모델을 생성하는 방식과 업종별로 딥러닝 모델을 생성하는 방식이다. 두 가지 방식을 비교하기 위해 LSTM 모델을 사용한 보간 모델 실험을 수행한다. 전기사용자별 LSTM 모델은 전기사용자 수와 같은 200개의 모델을 생성한다. 업종별 LSTM 모델은 업종 class 수인 10개의 모델을 생성한다. 두 가지 방식의 딥러닝 모델의 효율성과 정확도를 비교하기 위해, 모델별 Error rate(MSE, Mean Squared Error) 평균과 표준편차, 학습시간을 측정한 결과는 표 2와 같다.

표 2 딥러닝 모델 생성 방식 비교

Table 2 Comparison of deep learning model creation methods

	Number of models	Error rate avg.	Error rate std.	Training time(sec)
Model by user	200	0.0729	0.0213	4575.8881
Model by business	10	0.0768	0.0078	1271.0944

전체 모델의 에러율 평균은 전기사용자별 모델 생성 방식이 낮았지만, 에러율의 표준편차는 업종별 모델 생성 방식이 낮았다. 전기사용자별 보간 모델의 정확도 편차가 크다고 볼 수 있다. 그리고 학습시간도 업종별 모델 생성방식과 비교하여 3.6배 이상 소요된다. 업종별 보간 모델을 생성할 경우 보간 모델의 안정성과 효율성 측면에서 전기사용자별 모델 생성방식 보다 유리하다.

3.3 LSTM과 GRU 모델 성능 비교 실험

업종별 보간 모델 생성방식을 사용하여 LSTM, GRU를 활용한 전력사용량 보간 모델링을 실험한다. 두 알고리즘에 동일한 학습 데이터와 하이퍼 파라미터를 적용하여 정확도(Accuracy)와 학습 실행시간의 차이를 비교하여 분석한다.

전체 데이터는 시간 순서에 따른 모델 편향을 제거하기 위하여 랜덤하게 일자를 섞어서 학습:검증:테스트=7:1:2으로 분할하여 수행한다. 학습 반복 횟수(Epoch)는 100으로 설정하였고, 딥러닝 모델의 과적합을 방지하기 위해 연속 10회 이상 오차 값(loss)이 변하지 않는 경우 학습을 강제 종료하도록 명령을 삽입하였다. LSTM과 GRU의 loss function은 MSE(Mean Squared Error), optimizer는 Adam(Adaptive Moment Estimation)을 사용

하였다. 모델 평가는 오차에 동일한 가중치를 적용하기 위하여 MAE(Mean Absolute Error)를 사용한다.

모델 정확도의 평가지표는 MAPE(Mean Absolute Percentage Error), R2 Score를 검토하였다. MAPE는 직관적으로 에러율을 판단하기에 좋으나, 학습 데이터가 0값에 가까운 값이 존재하여 스케일 측면에서 부적합하여 R2 Score를 평가지표로 선정한다. R2 Score 측정을 위해 스케일한 전력사용량 값을 다시 복원하여 실제값과 예측값의 차이를 계산한다.


모델 정확도와 학습 실행시간 측정 결과는 표 3과 같다.

표 3 LSTM, GRU 모델 정확도, 학습 시간 비교


Table 3 Comparison of LSTM, GRU model accuracy and training time

	LSTM(A)	GRU(B)	(A-B)
Accuracy (R2 Score)	0.9628	0.9589	0.0039
Training time (sec)	1271.0944	1085.8544	185.24


(1) Forward LSTM prediction result sample



(2) Backward LSTM prediction result sample



(3) Bi-directional LSTM prediction result sample



(4) Forward-backward LSTM avg. prediction result sample




그림 4 4가지 LSTM 모델의 전력사용량 데이터 실제값과 예측값 비교 그래프

Fig. 4 Comparison graph between actual and predicted values of electricity consumption data of four LSTM models

측정 결과 학습 정확도는 LSTM이 GRU와 비교하여 정확도는 0.0039 높았고, 학습 실행시간은 185.24초 늦었다. 보간 모델의 경우 결측치의 정확한 실제값을 예측하는 문제로 어려움이 무엇보다 중요하다. GRU가 속도 측면에서 이득이긴 하지만 어려움이 LSTM보다 높기 때문에 보간 모델에서는 LSTM을 사용하는 이득이 더 크다. 다음 단계에서는 LSTM을 활용하여 보간 모델 개선을 수행한다.

3.4 LSTM 보간 모델 실험 결과

보간 모델은 일반적인 회귀 모델과는 달리 결측 데이터의 시점을 중심으로 과거와 미래 데이터가 존재한다. 그렇기 때문에 LSTM을 양방향으로 적용하여 결측치 예측이 가능하다.[8] 다른 연구 사례에서도 시계열 데이터에서 양방향 LSTM 모델이 조금 더 나은 성능을 보인 사례가 있다.[9, 10]

본 연구에서도 시계열 데이터의 양방향성을 고려한 성능을 비교하기 위하여 시계열 데이터의 순방향 모델인 forward LSTM 모델, 역방향 모델인 backward LSTM 모델, 양방향 모델인 Bi-directional LSTM 모델과 추가적으로 forward LSTM 모델과 backward LSTM 모델의 평균치를 예측값으로 사용하는 평균 모델(forward-backward LSTM 평균 모델)을 구현하였다. 다음은 1개의 데이터 샘플에 대하여 4가지 LSTM 모델의 전력사용량 실제값과 예측값을 비교한 그래프이다.

forward 모델, backward 모델, Bi-directional 모델 및 forward-backward 평균 모델의 테스트 데이터셋 정확도를 측정하여 비교한 결과는 표 4과 같다.

표 4 1시간 결측치 예측 모델 정확도

Table 4 1-hour missing value prediction model accuracy

	forward	backward	bi-directional	forward-backward Avg.
Accuracy (R2 Score)	0.9628	0.9706	0.9698	0.9753

1시간 데이터(결측치) 예측 모델 정확도는 forward-backward 평균 모델 > backward > bi-directional > Forward 순으로 나타났다. forward-backward 평균 모델이 가장 좋은 성능을 보인다.

실제 전력사용량 데이터의 결측은 연속적으로 나타날 수 있다. LSTM 활용 전력사용량 보간 모델의 실효성을 검증하기 위하여 2, 3시간 데이터(결측치) 예측 모델링을 추가 수행한다. 최종 결과는 표 5와 같다.

1~3시간 결측치 예측 모델의 평균 정확도는 forward-backward 평균 모델 > backward 모델 > forward model > bi-directional 모델 순으로 나타났다. 같은 하이퍼 파라미터 조건에서 unidirectional 모델이 bi-directional 모델보다 더 좋은 성능을 보였다. 가장 성능이 좋았던 forward-backward 모델의 경우 1시간, 3시간 결측치 예측 모델에 비해 2시간 결측치 예측 모델의 성능이 다소

표 5 1~3시간 결측치 예측 정확도(R2 Score)

Table 5 1-3 hour missing value prediction accuracy (R2 Score)

	forward	backward	bi-directional	forward-backward Avg.
1 hour prediction	0.9628	0.9706	0.9698	0.9753
2 hour prediction	0.9619	0.9605	0.9600	0.9526
3 hour prediction	0.9633	0.9643	0.9615	0.9747
Average of Accuracy	0.9627	0.9651	0.9615	0.9675

낮았으며, 모델의 안정성이 다소 떨어지는 것으로 보이지만, 4가지 예측 모델 모두 R2 Score가 0.95 이상으로 안정된 모델 성능을 나타냈다.

4. 결론

본 연구에서는 시스템적인 요인으로 발생하는 전력사용량 데이터의 결측치를 보간하기 위해 업종별로 보간 모델을 생성하는 방식을 사용하였고, LSTM을 활용한 전력사용량 데이터 보간 방법을 실험하였다. 기존에는 전기사용자의 과거 패턴으로 전력사용량 데이터를 보간하는 방법을 사용하였는데, 이 방법은 모델별로 성능의 편차가 발생하는 문제가 있는데, 업종별 모델 생성방식을 사용하여 모델의 안정성을 높이고, 학습 시간을 3배 이상 감소시킬 수 있었다. 그리고 Forward LSTM 모델과 backward LSTM 모델의 평균값을 사용하는 forward-backward LSTM 평균 모델로 기존 연구에서 제안했던 bi-direction LSTM 방식보다 성능을 개선할 수 있었다. 전력사용량 데이터는 다양한 분야의 데이터와 결합하여 활용될 수 있는 가치가 높은 데이터이다. 전력과 통신 데이터를 결합하여 사회취약계층을 모니터링하는 서비스가 대표적인 사례이다. 전력사용량 데이터의 결측치 보간 방법의 정확도를 향상시키면 고품질 데이터를 이용하여 다양한 분야의 서비스를 개발하는데 활용할 수 있다.

References

- [1] Taegon Kim, Jinyeong Lee, MinSeok Jang, Jae-Hee Lee, Young-Min Wi, "Advanced Metering Infrastructure Missing data imputation using Long Short-Term Memory", The Korean Institute of Electrical Engineers, pp.762-763, 2022.
- [2] Hyuk-Rok Kwon, Taek-Eun Hong, Pan-Koo Kim, "Estimate method of missing data using Similarity in AMI system," Korean Institute of Smart Media, pp.80-84, 2019.
- [3] Lee Wooseop, Kim Hyungkyoo. "Prediction Model of Average Temperature based on Characteristic of Urban-space Using LSTM and GRU: The Case of Wonju City," The

- Korea Spatial Planning Review, pp.89-104, 2021.
- [4] Sepp Hochreiter 외 1명, “LONG SHORT-TERM MEMORY,” NEURAL COMPUTATION 9(8), pp.1735-1780, 1997.
 - [5] Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. “Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation,” In Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar. Association for Computational Linguistics, pp.1724–1734, 2014.
 - [6] Nae Won Kwak, Dong Hoon Lim, “Financial time series forecasting using AdaBoost-GRU ensemble model,” Journal of the Korean Data And Information Science Society, 32(2), pp.267-281. 2021.
 - [7] Eden Kim, Seok-gab Ko, Seung-cheol Son, Byung-tak Lee, “Trends in Time Series Data Missing Value Handling Technology”, ETRI DOI, S0317-21-1001, 2021.
 - [8] Wei Song, Chao Gao, Yue Zhao and Yandong Zhao, “A Time Series Data Filling Method Based on LSTM—Taking the Stem Moisture as an Example, MDPI Sensors, 20(18), pp.5045, 2020.
 - [9] Ko Sangjun, Ho-young Yun, Dong-Myung Shin, “Electronic Demand Data Prediction using Bidirectional Long Short Term Memory Networks,” Journal of Software Assessment and Valuation, 14(1), pp.33-40. 2018.
 - [10] YongTak Shin, Dong-Hoon Kim, Hyeon-Jae Kim, Chaewook Lim, Seung-Buhm Woo, “Imputation of Missing SST Observation Data Using Multivariate Bidirectional RNN,” Journal of Korean Society of Coastal and Ocean Engineers, 34(4), pp.109- 118, 2022.